



Curso especialización de Inteligencia Artificial y Big Data

Sistema de Análisis del Mercado de Automoción

Cristian Cabrera Pinto y Álex Rafael de la Cruz Sánchez

Marzo 2026



Big Data

Índice

1. Introducción	5
2. Datos.....	5
2.1. Datos del fichero vehículos.json.....	5
2.2. Datos del fichero ventas_mantenimiento.csv	6
2.3. Datos de opiniones-clientes.xml.....	7
3. Fase 1: Selección y comprensión del dominio	8
3.1. Análisis Exploratorio del Dominio	8
a) Analizar distribución de marcas, modelos y segmentos.....	8
b) Identificar relaciones entre características técnicas y precios.....	10
c) Estudiar patrones de ventas y mantenimiento	11
d) Documentar hipótesis sobre factores que afectan valor residual	14
3.2. Definición de Objetivos de Minería.....	14
4. Fase 2: Preprocesamiento y limpieza	15
4.1. Integración de múltiples fuentes.....	15
4.2. Limpieza y tratamiento de valores anómalos	16
4.3. Ingeniería de características	17
a) Creación de características.....	17
b) Análisis de correlación y eliminación de características.....	19
5. Fase 4: Minería de Datos.....	20
5.1. Árboles de decisión para predecir el valor residual.....	25
5.2. Regresión múltiple para precios.....	27
5.3. Análisis de sentimientos en reviews usando Naive Bayes	29
5.4. Detección de anomalías en los precios.....	31
5.5. Reseñas contradictorias.....	33
5.6. Predicción de precio de venta	34
6. Fase 5: Interpretación y Evaluación.....	42
6.1. Algoritmos para la clasificación del segmento de mercado	42
6.2. Sistema de recomendación.....	44
7. Conclusión y resolución de objetivos	46

Índice de imágenes

Ilustración 1: Gráfico de la distribución de vehículos por marca.....	8
Ilustración 2: Gráfico de la distribución de vehículos por modelo.....	9
Ilustración 3: Gráfico del precio base por segmento.	9
Ilustración 4: Correlación entre variables técnicas y económicas con el precio base.	10
Ilustración 5: Correlación entre el kilometraje y el precio de ventas.....	12
Ilustración 6: Correlación entre indecencias y coste de mantenimiento.	13
Ilustración 7: Correlación entre antigüedad y coste de mantenimiento.	13
Ilustración 8: Boxplot de detección de outliers en precio de venta.	16
Ilustración 9: Correlaciones de todas las variables numéricas.	19
Ilustración 10: Relación lineal entre potencia y precio de venta.	20
Ilustración 11: Importancia del combustible en el precio.	21
Ilustración 12: Relación ente el mantenimiento y el precio de venta.	21
Ilustración 13: Segmentación de vehículos por tipo de combustión.	22
Ilustración 14: Relación entre el precio base y el coste de mantenimiento.	23
Ilustración 15: Predictores del coste de mantenimiento.	23
Ilustración 16: Gráficas para el análisis de patrones de precios por región.	24
Ilustración 17: Distribución de las ventas por meses.....	24
Ilustración 18: Relaciones de variables con el valor residual.	25
Ilustración 19: Importancia de las variables en la predicción del valor residual.	26
Ilustración 20: Árbol de decisión para valor residual.	26
Ilustración 21: Importancia de variables en la predicción del precio.....	27
Ilustración 22: Gráfico del precio real vs el predicho.	28
Ilustración 23: Matriz de confusión para el análisis de sentimientos.	29
Ilustración 24: Influencia del sentimiento en el precio.	30
Ilustración 25: Característica que predicen reseñas positivas.....	31
Ilustración 26: Gráficos de anomalías en los precios según tipo para KNN.	31
Ilustración 27: Gráficos para anomalías de los precios según tipo para SVM.	32
Ilustración 28: Gráfico de las anomalías para los dos modelos combinados. ...	33
Ilustración 29: Visualización de reseñas contradictorias.	34
Ilustración 30: Gráfica del valor real vs predicho de la regresión lineal múltiple.	35
Ilustración 31: Gráfico de residuos de la regresión lineal múltiple.....	36
Ilustración 32: Gráfico del valor real vs predicho con el árbol de decisión.	37
Ilustración 33: Gráfico de residuos del árbol de decisión.	37
Ilustración 34: Gráfico de valor real vs predicho para el modelo SVM.	38
Ilustración 35: Gráfico de residuos del modelo SVM.....	39
Ilustración 36: Gráfico del valor real vs predicho del modelo perceptrón multicapa.....	40
Ilustración 37: Gráficos de residuos del modelo perceptrón multicapa.	40
Ilustración 38: Gráfico de la importancia de variables para definir el segmento.	42
Ilustración 39: Gráfica comparativa de los modelos de clasificación de segmento de mercado.....	43

Índice de tablas

Tabla 1: Datos que contiene el fichero de vehículos	6
Tabla 2: Datos que contiene el fichero de ventas y mantenimiento.	7
Tabla 3: Datos que contiene el fichero de opiniones de clientes.....	7
Tabla 4: Comparación de modelos de los puntos 4.2 y 4.5.....	34
Tabla 5: Evaluación de los modelos para la segmentación del mercado.	43

1. Introducción

El objetivo principal del este proyecto es el desarrollo de un sistema de análisis del mercado de automoción centrado en la venta de vehículos de segunda mano. Para ello, se aplicará la metodología KDD (Knowledge Discovery in Databases), donde a través de diferentes fases se busca extraer el conocimiento para la toma de decisiones estratégicas.

Contamos con tres conjuntos de datos: uno con las especificaciones técnicas de los vehículos, otro con el histórico de ventas y mantenimiento de las diferentes marcas y modelos y el último que contiene opiniones de clientes.

Esta práctica permitirá desarrollar un proceso de obtención de conocimiento a partir de una serie de datos, formulando preguntas de investigación, construyendo hipótesis, realizando análisis exploratorio, aplicando técnicas de minería de datos y evaluando los resultado obtenidos.

2. Datos

Los datos proporcionados para la realización de este sistema de análisis son:

- El fichero vehículos.json, con características técnicas.
- El archivo venta_mantenimiento.csv, con histórico de ventas y mantenimiento.
- El conjunto de opiniones de clientes en el fichero opiniones-clientes.xml.

2.1. Datos del fichero vehículos.json

Este fichero contiene el catálogo de vehículos con los que se va a tratar. En concreto cuenta con 300 vehículos identificados con un identificador y 12 características más que permiten describir a cada vehículo. Las variables son las siguientes:

Variable	Descripción	Tipo	Dominio
Vehiculo-id	Identificador único	Categorico	Código alfanumérico
Marca	Mara de los coches	Categorico	12 marcas de coches distintos
Modelo	Modelos de cada marca	Categorico	Ciertos modelos específicos
Anio-fabricacion	Año en el que se fabricó el coche	Numérico	Años entre 2018 y 2024
Combustible	Tipo de combustible que usa el vehículos	Categorico	Híbrido, Gasolina, Diésel, Eléctrico
Transmision	Tipo de transmisión del vehículo	Categorico	Manual, automático

Potencia-cv	Potencia del motor en CV	Numérico	Valores entre 90 y 336
Cilindrada	Cilindros que tiene el coche	Numérico	Valores típicos
Consumo-urbano	Consumo urbano del vehículo	Numérico	Litros consumidos cada 100 km
Consumo-extraurbano	Consumo en carretera	Numérico	Litros consumidos cada 100 km
Emisiones-co2	Emisiones del vehículo	Numérico	Rango de emisiones
Precio-base	Precio el vehículo	Numérico	Precio de catálogo
Segmento	Grupo del vehículo	Categorico	Compacto, Sedán, Deportivo, SUV, Executive.

Tabla 1: Datos que contiene el fichero de vehículos

2.2. Datos del fichero ventas_mantenimiento.csv

Este fichero contiene el registro transaccional de las ventas realizadas y el estado del vehículo en el momento de la operación. Se trata de un conjunto de 600 transacciones que cuentan con un identificador propio y con el identificador del vehículo para poder unir los datasets. Además tiene otras 8 variables que permiten describir las transacciones. Las variables de este dataset son:

Variable	Descripción	Tipo	Dominio
Venta-id	Identificador único de venta	Categorico	Código alfanumérico
Vehiculo-id	Identificador único del vehículo	Categorico	ID del vehículo
Fecha-venta	Fecha de la operación	Fecha	Fecha en formato YYYY-MM-DD
Region-vendedor	Región de España del vendedor	Categorico	Distintas regiones de España
Precio_venta_real	Precio final de la venta	Numérico	Rango de precios
Kilometraje_venta	Kilometros del vehículo	Numérico	Rango de Km

Servicios_realizados	Visitas al taller previas	Numéricas	Valor entre 0 y 6
Coste_mantenimiento_anual	Coste medio de mantenimiento	Numérico	Rango de precio
Incidencias_mecánicas	Averías registradas	Numérico	Valores de 0 a 3
Valor_residual_estimad	Valoración actual, precio recalculado	Numérico	Rango de precio

Tabla 2: Datos que contiene el fichero de ventas y mantenimiento.

2.3. Datos de opiniones-clientes.xml

Este fichero contiene el feedback cualitativo y puntuaciones de los clientes. En concreto cuenta con un total de 500 opiniones identificadas por un identificador único y que se asocia al identificador del vehículo y del cliente. Además cuenta con otras 8 características. Las variables que tiene son:

Variable	Descripción	Tipo	Dominio
Review_id	Identificador único de la opinión	Categórico	Código alfanumérico
Vehiculo_id	Identificador del vehículo	Categórico	ID del vehículo
Cliente_id	Identificador del cliente	Categórico	ID del cliente
Puntuación_conjunta	Nota global del vehículo	Numérico	Rango entre 1 y 5
Confort	Nota del confort	Numérico	Rango entre 1 y 5
Seguridad	Nota de seguridad	Numérico	Rango entre 1 y 5
Eficiencia	Nota de eficiencia	Numérico	Rango entre 1 y 5
Diseño	Nota de diseño	Numérico	Rango entre 1 y 5
Fiabilidad	Nota de fiabilidad	Numérico	Rango entre 1 y 5
Recomendación	Es recomendado el vehículo	Binario	Si/No
Texto_review	Texto de la opinión del cliente	Texto	Comentario del cliente

Tabla 3: Datos que contiene el fichero de opiniones de clientes.

3. Fase 1: Selección y comprensión del dominio

3.1. Análisis Exploratorio del Dominio

a) Analizar distribución de marcas, modelos y segmentos

El objetivo de este primer apartado es comprender la composición del conjunto de datos, identificando cómo se distribuyen los vehículos según marca, modelo y segmento de mercado. Este análisis permite detectar posibles sesgos en los datos y entender qué tipos de vehículos están más representados.




Ilustración 1: Gráfico de la distribución de vehículos por marca.

- Observamos que marcas generalistas como Kia, Peugeot, Ford o Toyota concentran un mayor número de vehículos.
- Las marcas premium (BMW, Mercedes, Renault) aparecen en menor proporción, pero siguen teniendo una presencia relevante.
- Esta distribución es coherente con el mercado real, donde los vehículos de las marcas más asequibles dominan en volumen de ventas.

Análisis de modelo




Ilustración 2: Gráfico de la distribución de vehículos por modelo

- Detectamos una alta variedad de modelos, sin que uno solo monopolice el conjunto de datos, aunque algunos predominan más que otros.
- Algunos modelos más vendidos aparecen con mayor frecuencia, lo cual es coherente con su alta demanda en el mercado.
- La diversidad de modelos aporta riqueza al análisis y evita conclusiones sesgadas hacia un único tipo de vehículo.

Análisis de segmento




Ilustración 3: Gráfico del precio base por segmento.

- Los vehículos Sedán y compacto tienen los precios más altos registrados
- También se puede observar los valores de venta medios de cada segmento
- Los vehículos SUV tienen una gran cantidad de outliers en cuanto a sus precios de venta

b) Identificar relaciones entre características técnicas y precios

Para este análisis hemos seleccionado las siguientes variables técnicas y económicas:

- potencia_cv
- cilindrada
- consumo_urbano
- consumo_extraurbano
- emisiones_co2
- precio_base

Estas variables han sido elegidas porque representan:

- Prestaciones del vehículo (potencia, cilindrada)
- Eficiencia y sostenibilidad (consumos y emisiones)

Calculamos la matriz de correlación entre las variables seleccionadas con el fin de identificar relaciones lineales entre características técnicas y precio.




Ilustración 4: Correlación entre variables técnicas y económicas con el precio base.

- Relación fuerte entre potencia_cv y precio_base (0.84). Los vehículos con mayor potencia tienden a presentar precios base más elevados, lo que indica que las características del motor son un factor determinante en el valor del vehículo.
- Relación negativa entre cilindrada y precio_base (-0.67). Una mayor cilindrada no implica necesariamente un mayor precio base.
- Relación negativa entre cilindrada y precio_base (-0.67). Una mayor cilindrada no implica necesariamente un mayor precio base.
- Relación negativa entre precio base y consumo_urbano (-0.61) y relación negativa entre precio base y consumo_extraurbano (-0.59). Los vehículos con menores consumos tienden a tener precios base más altos.
- Relación negativa entre emisiones_co2 y precio_base (-0.73). Vehículos con menores emisiones presentan precios base más elevados.
- Relación fuerte entre cilindrada y consumo_urbano (0,73) / consumo_extraurbano (0,72). Esto implica que a mayor cilindrada de los vehículos más consumo tendrá el vehículo.
- Relación negativa entre potencia_cv y consumos (-0,31|-0,32) / emisiones (-0,43). Estas relaciones indican que la potencia no depende únicamente de la cilindrada, y que existen vehículos de alta potencia con tecnologías más eficientes, como híbridos o eléctricos.

c) Estudiar patrones de ventas y mantenimiento

- Análisis descriptivo de ventas y mantenimiento: Realizamos un análisis de ventas y mantenimiento con las siguientes variables:
 - precio_venta_real
 - kilometraje_venta
 - coste_mantenimiento_anual
 - incidencias_mecanicas

Resultados:

- El precio medio de venta real se sitúa en torno a los 34.000 €.
- El kilometraje de venta representa mucha diferencia entre los vehículos con los kilometrajes más bajos y los más altos.
- La mayoría de vehículos presentan pocas o ninguna incidencia mecánica.
- El coste de mantenimiento anual muestra variabilidad entre vehículos.

- Relación entre kilometraje y precio de venta:




Ilustración 5: Correlación entre el kilometraje y el precio de ventas.

La correlación entre el kilometraje y el precio de venta real es muy débil y cercana a cero, lo que indica que, en este conjunto de datos, el kilometraje por sí solo no explica de forma significativa el precio de venta.

- Coste de mantenimiento por marca:

Se observan diferencias claras en el coste medio de mantenimiento entre marcas. Las marcas de gama más alta presentan costes de mantenimiento más elevados, mientras que las marcas más baratas tienden a mostrar costes inferiores.

- Coste de mantenimiento e incidencias:




Ilustración 6: Correlación entre incidencias y coste de mantenimiento.

La relación entre el número de incidencias mecánicas y el coste de mantenimiento anual es débil, lo que sugiere que los costes de mantenimiento no dependen únicamente del número de averías.

- Coste de mantenimiento y antigüedad:




Ilustración 7: Correlación entre antigüedad y coste de mantenimiento.

Se observa una correlación positiva moderada entre la antigüedad del vehículo y el coste de mantenimiento anual, indicando que los vehículos más antiguos tienden a requerir mayores gastos de mantenimiento.

d) Documentar hipótesis sobre factores que afectan valor residual

En este apartado se formularán las hipótesis que serán respondidas en fases posteriores mediante modelos predictivos.

- Observamos una correlación positiva moderada entre la antigüedad del vehículo y el coste de mantenimiento, lo que sugiere un mayor desgaste y una menor percepción de valor en vehículos más antiguos.
- Aunque la correlación directa entre kilometraje y precio de venta es débil en esta fase, el kilometraje sigue siendo un indicador del uso del vehículo y, combinado con otras variables, puede influir en el valor.
- Las diferencias observadas en el coste de mantenimiento por marca y su relación con la antigüedad indican que los costes de mantenimiento pueden afectar negativamente a la percepción de valor del vehículo.
- Aunque la correlación directa es débil, las incidencias mecánicas reflejan problemas de fiabilidad que pueden influir en el precio de venta y en el valor residual a largo plazo.
- El análisis de correlación entre variables técnicas y precio base muestra que la eficiencia energética y las prestaciones influyen positivamente en la valoración económica del vehículo.
- Las puntuaciones y recomendaciones reflejan la satisfacción del cliente y pueden influir en la demanda y en el valor del vehículo.

3.2. Definición de Objetivos de Minería

- ¿Qué características determinan el precio de un vehículo?

Se plantea analizar qué variables técnicas (potencia, consumo, emisiones), comerciales (segmento, marca) y de percepción del cliente influyen de forma significativa en el precio del vehículo.

- ¿Podemos segmentar vehículos por perfil de uso y eficiencia?

Se propone segmentar los vehículos en función de su perfil de uso y eficiencia energética, utilizando variables como consumo, emisiones, tipo de combustible y kilometraje.

- ¿Qué factores predicen los costes de mantenimiento?

Se analizará la relación entre antigüedad, kilometraje, incidencias mecánicas, marca y costes de mantenimiento anual para identificar los factores que influyen en el gasto de mantenimiento.

- ¿Existen patrones en las ventas por temporada y región?

Se estudiarán posibles patrones temporales y geográficos en las ventas de vehículos, considerando la fecha de venta y la región del vendedor.

- ¿Cómo predecir el valor residual de un vehículo?

Se plantea la construcción de modelos predictivos que permitan estimar el valor residual del vehículo a partir de características técnicas, de uso, mantenimiento y percepción del cliente.

- ¿Influye la percepción del cliente en el precio del vehículo?

Dado que se dispone de información sobre valoraciones y recomendaciones de los clientes, resulta relevante analizar si estas opiniones del vehículo influyen en su valor.

- ¿Es posible detectar vehículos con precios anormales a partir de sus características?

Posibilidad de identificar vehículos con precios anormales mediante el uso de técnicas de detección de anomalías basadas en características técnicas, de uso y de mantenimiento.

4. Fase 2: Preprocesamiento y limpieza

4.1. Integración de múltiples fuentes

El objetivo de esta fase es consolidar la información de las tres fuentes en un conjunto de datos combinado que servirá como base para los modelos que se aplicarán en fases posteriores.

El primer paso ha sido la construcción de un dataset unificado al que se ha priorizado la integridad transaccional de los datos de ventas.

- Integración Ventas-Vehículos: Hemos realizado una unión (Left Join) entre el histórico de ventas y el catálogo de vehículos. Dado que la cardinalidad es de N:1 (muchas ventas pueden referirse al mismo modelo de coche), esta operación es segura y enriquece cada venta con sus especificaciones técnicas sin alterar el número de registros (600 transacciones).
- Hemos decidido no integrar la tabla de opiniones en esta fase preliminar. El motivo es la naturaleza "uno a muchos" de las reseñas (un vehículo tiene múltiples opiniones). Una unión directa duplicaría los registros de ventas, introduciendo sesgo en los futuros modelos de predicción de precios. Y si se tratara de unir haciendo medias y modas se perdería el texto de las reseñas y por lo tanto información útil para posibles modelos de análisis de sentimiento.

El siguiente paso es detectar posibles valores que se salgan de la realidad, pero no se ha detectado nada fuera de lo común en un primer vistazo. Del mismo modo que haciendo una inspección de valores nulos hemos comprobado que este no es el caso para ninguno de los dos datasets con los que trabajaremos.

4.2. Limpieza y tratamiento de valores anómalos

En esta etapa vamos a comprobar la calidad de los datos, identificando valores atípicos y aplicando transformaciones necesarias para mejorar el rendimiento de los futuros modelos de aprendizaje automático.

El primer paso ha sido la detección de outliers en los precios de los vehículos, donde hemos comprobado que existen valores que se van más allá del valor máximo no atípico, como se puede observar en el siguiente *boxplot*:




Ilustración 8: Boxplot de detección de outliers en precio de venta.

Pero hemos comprobado a qué tipo de vehículos se corresponden y se trata de vehículos de gama alta, por lo que estos valores no son errores, sino precios legítimos. Eliminarlos sesgaría los modelos, impidiendo la predicción correcta de vehículos de gama alta.

El segundo paso ha sido la verificación de cilindrada y consumos imposibles. En este caso hemos observado que existen valores de cilindrada cero, por lo que hemos tenido que comprobar si estos eran o no eléctricos, de modo que hemos visto que todos los que tienen una cilindrada de cero se corresponden con vehículos eléctricos por lo tanto no hay errores. Y en cuanto al consumo, no hemos encontrado valores negativos ni consumos imposibles (0 L/100km en

coches de combustión o > 20 L/100km) sino que no pasan los consumos más altos de 9 L/100km.

El siguiente paso ha sido comprobar si existen puntuaciones *missing*, para ello hemos cruzado el dataset de ventas y opiniones donde hemos podido observar que existe una cantidad de ventas de vehículos que no tienen reseñas. Sin embargo, el fichero original de opiniones no presenta valores nulos por lo que la ausencia de datos se debe exclusivamente a vehículos que no han recibido feedback. De modo que al tratarse de información subjetiva y no estructural no vamos a darle valores artificiales (media, moda) porque induciría un sesgo falso a modelos como pueden ser de sentimiento y predicción.

Y por último, hemos normalizado variables técnicas como la potencia y la cilindrada para evitar que variables con escalas grandes) dominen sobre variables pequeñas en algoritmos basados en distancia (como K-Nearest Neighbors o SVM), hemos aplicado una normalización *Min-Max*.

4.3. Ingeniería de características

a) Creación de características

Hemos creado variables a partir de las existentes para poder extraer nuevo conocimiento de los datos. Estas variables han sido:

- Antigüedad: Representa la edad del vehículo, teniendo en cuenta que el año actual es 2026.
- Eficiencia global: Es la media del consumo urbano y el extraurbano, proporcionando una métrica unificada del gasto de combustible.
- Ratio precio potencia: Es el resultado de la división entre el precio base del coche y la potencia. Indica cuánto cuesta cada caballo de potencia, siendo útil para identificar coches sobrevalorados o “gangas”.
- Categoría de emisiones: Variable categórica basada en las emisiones del CO₂, teniendo en cuenta que: *Eco* si emisiones menores a 110 g/km, *media* si emisiones entre 110 – 150 g/km y *contaminante* si emisiones mayores a 150 g/km.
- Depreciación anual: Medida para determinar la pérdida de valor del coche por año usado.
- Índice de fiabilidad: Variable que combina datos objetivos (incidencias) y datos subjetivos (opiniones de la fiabilidad). Hemos creado un promedio entre la fiabilidad y las incidencias que si tiene un valor alto indica que el coche es robusto. Se trata de un valor entre 0 y 1, cuanto más cerca de 1 este el índice de fiabilidad más robusto será el coche.

Una vez creadas las nuevas variables, para poder hacer un correcto análisis de correlación, hemos realizado un tratamiento a ciertas variables categóricas y temporales. Los tratamientos han sido:

- Tratamiento geográfico (región del vendedor): Analizada la variable detectamos una baja cardinalidad (tan solo hay 5 comunidades), de modo que hemos podido aplicar la creación de variables dummy por medio de *One-Hot Encoding* lo que permitirá visualizar el mapa de calor del impacto de cada región sobre el precio. Para la visualización de la matriz de correlación se han mantenido las 5 variables dummy con el fin de observar todas las relaciones. No obstante, en la fase de modelado (Fase 4) se eliminará una de ellas para evitar la colinealidad perfecta.
- Descomposición temporal: Hemos desglosado la fecha de venta en mes y año, lo que puede permitir detectar patrones estacionales y tendencias anuales.
- Tipo de combustible: Al tener 4 categorías aplicamos el *One-Hot Encoding* porque si le damos valores numéricos como (1, 2, 3, 4), los modelos pueden llegar a pensar que el 4 es el doble que el 2 y eso no es real, sino que queremos ver si el tipo de combustible dispara el precio. Del mismo modo que en las regiones vamos a mantener las 4 variables dummies creadas para ver todas las relaciones. Pero en la fase de modelado tendremos que quitar una de ellas para evitar la colinealidad perfecta.
- Codificación de variables categóricas: Codificamos variables como el segmento, la categoría de emisiones y la transmisión a escalas numéricas para poder medir la correlación lineal.

b) Análisis de correlación y eliminación de características




Ilustración 9: Correlaciones de todas las variables numéricas.

Basándonos en la matriz de correlación resultante, para reducir la dimensionalidad y evitar la redundancia vamos a eliminar las siguientes características:

- Consumo urbano y consumo extraurbano: Tienen un coeficiente de Pearson muy alto con la eficiencia global, puesto que estos datos ya están capturados en la nueva variable. De modo que mantener estas dos características haría al modelo equivocarse al contar la misma información 3 veces.
- Año de fabricación: Tiene una correlación inversa perfecta con la antigüedad. Por lo que nos quedamos con esta última ya que es una magnitud más directa y lógica para un modelo predictivo.
- Fecha de venta: Tiene un formato que no se puede procesar y al haber extraído ya el valor informativo del mes y año de venta la fecha original se vuelve innecesaria.
- Fiabilidad media: Es una variable extraída de las opiniones. La eliminamos porque ya forma parte del índice de fiabilidad, de modo que si se quedara duplicaríamos la importancia de la opinión del cliente.

Otras consideraciones a tener en cuenta es la eliminación de los identificadores. Los cuales se mantienen para poder identificar el coche, pero estas nunca se usarán para entrenar sino que habrá que excluirlas a la de entrenar los modelos. Y habrá que tener en cuenta también que no se ha eliminado ninguna de las variables dummies creadas de modo que podría provocar redundancia en los modelos por lo que a la hora de entrenar modelos si se usan esas variables tendremos que eliminar una de las variables para evitar la colinealidad perfecta.

5. Fase 4: Minería de Datos

A continuación se presentan una serie de conclusiones extraídas del conjunto de datos con el que trabajaremos en esta fase:

1. ¿Qué características determinan el precio de un vehículo?

- La potencia es el determinante número uno. La relación es lineal y casi perfecta: el precio del vehículo es prácticamente una función de sus caballos de fuerza. Si quieres saber el precio, mira la potencia.




Ilustración 10: Relación lineal entre potencia y precio de venta.

- El tipo de combustible presenta una alta importancia en el precio cuando se trata de vehículos eléctricos (como se puede ver en las correlaciones de la fase 2). Y la cilindrada muestra una importancia negativa, esto es debido a que los vehículos eléctricos aparecen como cilindrada con valor de 0. Esto confirma que el mercado está dividido en dos. Los vehículos eléctricos tienen un precio base tan elevado que distorsionan el mercado. Tener un motor de combustión grande ya no garantiza un precio alto si se compara con los eléctricos.




Ilustración 11: Importancia del combustible en el precio.

- Contra todo pronóstico, la antigüedad no influye en el precio en esta muestra. Con un coeficiente cercano a cero, los datos indican que la depreciación por años es despreciable frente al impacto de ser un coche potente o eléctrico. Un coche viejo potente sigue valiendo más que uno nuevo básico.
- Otra variable que parece importante es el coste de mantenimiento anual. Existe una correlación positiva muy alta. Cuanto más caro es mantener el coche, más caro es comprarlo. El coste de mantenimiento actúa como un indicador de lujo y complejidad. Los coches de alta gama y los eléctricos tienen costes de taller más elevados.




Ilustración 12: Relación ente el mantenimiento y el precio de venta.

- Y por último, otra de las variables que presentan relación con el precio son las emisiones de CO2. Ya que presentan una correlación negativa muy fuerte. A menos emisiones, más precio. Al igual que con la cilindrada, esto no es una conciencia ecológica del mercado, sino un efecto tecnológico. Ya que en el dataset los vehículos con emisiones de 0 son los eléctricos que son los coches más caros de dataset.

2. ¿Podemos segmentar vehículos por perfil de uso y eficiencia?

El análisis de clústeres visual (potencia_cv vs eficiencia_global) revela que la segmentación tradicional (Sedán, SUV, Compacto) es difusa en este mercado. Sin embargo, surge una segmentación tecnológica nítida que divide el mercado en dos mundos, los coches eléctricos y los coches que tienen combustión. La variable que mejor segmenta el parque no es el segmento comercial (que muestra medias muy parecidas entre Compactos y Deportivos en este dataset), sino la tecnología de propulsión.




Ilustración 13: Segmentación de vehículos por tipo de combustión.

3. ¿Qué factores predicen los costes de mantenimiento?

El análisis de correlación sobre la variable de coste de mantenimiento anual revela que el gasto de taller no es aleatorio, sino que sobre él influyen características como:

- El precio base del vehículo, es decir, dime cuánto costaba el coche y te diré cuánto cuesta mantenerlo. Los vehículos con un precio base alto tienen

componentes más complejos y caros, lo que eleva la factura anual independientemente de la edad.




Ilustración 14: Relación entre el precio base y el coste de mantenimiento.

- La potencia sugiere que a mayor rendimiento mayor será el coste de mantenimiento (frenos, neumáticos, revisiones...). Además, el tipo de vehículo también influye, ya que por ejemplo, el coste medio de mantenimiento de los vehículos eléctricos es de 1122€ y los de combustión 824€. Esto puede deberse a que los eléctricos de la muestra son de gama alta o requieren mano de obra especializada.
- Y otra de las características que afecta al coste de mantenimiento es la antigüedad del vehículo. Ya que a medida que el vehículo envejece, el coste anual se incrementa progresivamente (averías por desgaste, sustitución de piezas de vida útil limitada).




Ilustración 15: Predictores del coste de mantenimiento.

4. ¿Existen patrones en las ventas por temporada y región?

El análisis de la temporalidad de ventas y geográficos puede revelar ciertos patrones para la optimización de una estrategia comercial. Donde hemos descubierto:

- Existe una disparidad de precios notable. Madrid se consolida como la región más cara, con un precio medio de 35.892 €, mientras que Cataluña es la más económica con 32.897 € (una diferencia de casi 3.000 € por vehículo). Al profundizar en la venta por región, descubrimos que no es que los coches sean más caros en Madrid, sino que el tipo de vehículo es diferente:
 - Madrid lidera la adopción tecnológica: el 21,8% de sus ventas son Eléctricos y el 28,6% son marcas Premium (BMW, Mercedes, Audi).
 - Cataluña, en cambio, tiene una venta de eléctricos mucho menor (8,5%) y menos peso de marcas Premium (21,4%), lo que baja su ticket medio.




Ilustración 16: Gráficas para el análisis de patrones de precios por región.

- En cuanto al patrón estacional si miramos los meses de ventas podemos ver que las ventas no son constantes. El año comienza muy lento (Enero es el mes con menos operaciones, 37 unidades) y experimenta un crecimiento sostenido hasta alcanzar su pico en Mayo (57 unidades). A partir de junio, el mercado se estabiliza en torno a las 50 unidades mensuales, sin grandes caídas en verano. Curiosamente, el precio medio se mantiene relativamente estable durante todo el año (oscilando entre 33k€ y 36k€), lo que indica que la estacionalidad afecta al volumen de demanda, pero no devalúa el producto.




Ilustración 17: Distribución de las ventas por meses.

5. ¿Cómo predecir el valor residual de un vehículo?

El análisis de correlación y regresión demuestra que el valor residual no es una incógnita aleatoria, sino el resultado de una función de depreciación sistemática dominada casi exclusivamente por el tiempo:

- El tiempo es el factor dominante, ya que la variable antigüedad tiene una correlación negativa fortísima con el valor residual. El gráfico de dispersión revela una curva de depreciación clásica. El vehículo pierde valor muy rápidamente en los primeros 3-4 años y luego la caída se suaviza, estabilizándose en un valor residual mínimo.
- El precio base original actúa como el ancla. Vehículos más caros empiezan más alto y, aunque se deprecian al mismo ritmo porcentual, mantienen un valor absoluto mayor.
- Contra todo pronóstico, el kilometraje venta muestra una correlación nula con el valor residual estimado en este dataset. Esto sugiere que la fórmula utilizada para calcular este valor residual estimado se basa puramente en tablas de matrícula (años) y no penaliza el uso real del vehículo.




Ilustración 18: Relaciones de variables con el valor residual.

5.1. Árboles de decisión para predecir el valor residual

Nuestro objetivo es poder predecir el valor residual en base a los parámetros dados.

Dado que un mismo vehículo puede tener múltiples reseñas, se decidió agregar la información de opiniones a nivel de vehículo para evitar duplicación de observaciones y posibles sesgos.

Se aplicaron los siguientes criterios:

- Media para la variable puntuacion_conjunta, con el fin de obtener una medida representativa de la percepción global.
- Moda para la variable recomendación, al tratarse de una variable categórica.

Posteriormente se realizó un left join con el dataset de ventas para conservar todos los vehículos, independientemente de si disponían o no de reseñas. Este enfoque garantiza coherencia estructural: una fila representa un vehículo. También se determinó la importancia de las variables que hemos usado:

Las reseñas influyen en algunos segmentos (especialmente eléctricos), pero las características técnicas y de uso siguen siendo los principales determinantes del valor residual.

El modelo alcanzó una precisión aproximada del 80%, lo que indica una capacidad predictiva sólida para un problema multiclase.

El valor residual está principalmente determinado por variables estructurales y de uso del vehículo. Las reseñas influyen en determinados segmentos (por ejemplo, vehículos eléctricos), pero no constituyen el factor dominante.

Esto sugiere que el mercado de segunda mano sigue criterios técnicos objetivos más que percepciones subjetivas.

5.2. Regresión múltiple para precios.

En este apartado se intentará predecir con un random forest regressor el precio de venta de los vehículos, para ello vamos a:

- Usar nuestro dataset creado en el apartado anterior.
- Limitar su profundidad.
- División train/test 80/20 para entrenar.

Tras el entrenamiento del modelo se obtuvieron los siguientes resultados:

- $R^2 = 0.924$
- RMSE = 2.011.01
- MAE = 1555.72

Estos resultados indican que el modelo explica el 92% de la variabilidad del precio, con errores medios razonables dentro del rango habitual de precios. Las variables más relevantes fueron:




Ilustración 21: Importancia de variables en la predicción del precio.

Como se puede observar las variables más importantes son: la eficiencia global, la potencia y el tipo de fuel. La variable recomendación presenta baja importancia relativa.

Por último, revisamos la precisión del modelo con una tabla comparando el precio real con la predicción:




Ilustración 22: Gráfico del precio real vs el predicho.

Observamos que la mayoría de los puntos se concentran muy próximos a la diagonal, lo que indica una alta concordancia entre valores reales y predichos. Esto es coherente con el valor obtenido de: $R^2 = 0.924$. Lo que significa que el modelo explica aproximadamente el 92% de la variabilidad del precio real. Visualmente, el ajuste es sólido y estable a lo largo de todo el rango de precios.

Tras los resultados obtenidos podemos decir que:

a) ¿Qué características de las reseñas predicen mejor el precio?

La variable recomendación aporta cierta información, pero su impacto es reducido en comparación con variables técnicas.

b) ¿Son vinculantes las reseñas?

No son vinculantes. El precio está determinado principalmente por características objetivas. Las reseñas actúan como variable complementaria.

5.3. Análisis de sentimientos en reviews usando Naive Bayes

En esta fase aplicamos técnicas de Procesamiento de Lenguaje Natural (NLP) para transformar el texto no estructurado de las reseñas en información cuantificable. El objetivo es entrenar un modelo de clasificación supervisado (Naive Bayes) que nos permita entender qué factores técnicos impulsan la satisfacción del cliente.

Antes de llevar a cabo el entrenamiento lo primero que hemos hecho ha sido la limpieza del texto (eliminación de signos de puntuación) y la creación de la variable de sentimiento. En nuestro caso esta última ha sido creada a partir de la recomendación (variable binaria Si/No) y no a partir de otras como la puntuación conjunta porque: Las escalas numéricas introducen una zona gris subjetiva, En términos de marketing y ventas, el indicador más fiable de lealtad no es la nota media, sino la disposición del cliente a recomendar el producto y porque el clasificador Multinomial Naive Bayes funciona de manera óptima calculando probabilidades sobre categorías discretas.

Una vez tenemos el conjunto de datos el siguiente paso la vectorización para convertir las palabras en vectores numéricos. Esto permite dar más peso a palabras distintivas (ej: "avería", "robusto") y restar importancia a palabras comunes sin carga semántica.

Y por último se ha llevado a cabo el entrenamiento de un modelo Multinomial Naive Bayes a partir de un conjunto de entrenamiento (80% de datos). El modelo ha alcanzado un accuracy del 80% sobre el conjunto de test, esto valida que el lenguaje utilizado en las reseñas contiene patrones claros que permiten predecir la satisfacción del cliente con un alto grado de acierto.




Ilustración 23: Matriz de confusión para el análisis de sentimientos.

En esta matriz de confusión se puede ver que ha fallado diciendo el sentimiento es negativo cuando en realidad si sería positivo, pero esto también puede ser un

indicativo de que haya opiniones contradictorias a la recomendación en la que se ha basado el sentimiento final.

- ¿Cómo influye el sentimiento en los precios de los coches?: Existe una correlación positiva moderada entre el precio de venta y la probabilidad de recibir una reseña positiva. Los datos muestran que los vehículos de mayor precio tienden a satisfacer más a sus propietarios. Esto sugiere que el sobrecoste de estos vehículos se traduce en una experiencia de usuario superior, lo que justifica su precio en el mercado de segunda mano. Sin embargo, el precio no es una garantía absoluta: existen vehículos caros con críticas negativas, generalmente asociadas a costes de mantenimiento imprevistos.




Ilustración 24: Influencia del sentimiento en el precio.

- ¿Qué características predicen mejor las reseñas positivas?: El análisis de las características de los coches con recomendación "Sí" revela el perfil del "Coche Ideal" para el cliente donde destaca la fiabilidad, siendo esta el predictor más fuerte de satisfacción. Los vehículos con un alto índice fiabilidad y bajas incidencias mecánicas obtienen sistemáticamente reseñas positivas. La tranquilidad mecánica se valora por encima de las prestaciones.

También existe una relación entre la potencia y la satisfacción. Los coches potentes generan un vínculo emocional positivo, mientras que los coches con baja potencia suelen ser penalizados en las reseñas por falta de respuesta.

Además, el análisis agregado por marca muestra que fabricantes como BMW y Ford lideran el ranking de satisfacción (>68% de opiniones positivas), mientras que otras marcas generalistas sufren más penalizaciones en las reseñas, a menudo relacionadas con la durabilidad percibida.




Ilustración 25: Característica que predicen reseñas positivas.

5.4. Detección de anomalías en los precios

En este apartado vamos a crear dos modelos para la detección de anomalías en los precios de venta de los vehículos, un modelo KNN y otro SVM.

- KNN (K-Nearest Neighbors):** Este método asumirá que el precio de un coche debe ser similar al de sus vecinos más cercanos en características técnicas (potencia, antigüedad, kilometraje) y además teniendo en cuenta también aspectos de incidencias y servicios que han tenido los vehículos ya que tenemos que tener en cuenta que un coche puede estar devaluado por sus averías. Con este conjunto pensamos que las anomalías detectadas serán más precisas. En este algoritmo se buscan los k coches más parecidos, se calcula el precio promedio y si la diferencia entre el precio real y el precio estimado supera un umbral (hemos establecido el top 5% de mayores errores) se marca como anomalía.




Ilustración 26: Gráficos de anomalías en los precios según tipo para KNN.

Como se puede ver en los gráficos anteriores nos permite ver las anomalías detectadas en tres tipos de riesgo para el negocio de ventas:

- Anomalías mecánicas:** Precio frente al número de averías. Observamos puntos rojos en los que el algoritmo ha detectado que por su estado mecánico el coche debería ser más barato.
- Anomalías temporales:** Precio frente a la antigüedad. Los puntos rojos indican vehículos que no han seguido la depreciación natural.

- Anomalías de uso: Precio frente a kilometraje. Los vehículos son marcados como anomalías porque sus vecinos (similar kilometraje) se venden a diferente precio.
- **SVM (Support Vector Machine):** En este caso vamos a usar un SVR (Support Vector Regressor), que a diferencia del KNN trata de encontrar una función matemática global que explique el comportamiento general del precio. Al igual que en KNN hemos generado gráficas para ver que vehículos detecta como anomalías, dándonos lo siguiente:




Ilustración 27: Gráficos para anomalías de los precios según tipo para SVM.

Para una correcta interpretación de los resultados, es fundamental cruzar sus resultados. No todas las anomalías son iguales:

- Si solo K-NN lo detecta: Es una anomalía local (raro comparado con sus vecinos, pero quizás normal en el mercado global).
- Si solo SVM lo detecta: Es una anomalía de tendencia (se sale de la curva matemática, pero quizás tiene vecinos parecidos).
- Si AMBOS lo detectan: Es una Anomalía Crítica. Aquí es donde hay una probabilidad altísima de error de precio o fraude.

De modo que hemos obtenido la siguiente gráfica en la que se puede ver mejor estas situaciones descritas con anterioridad.




Ilustración 28: Gráfico de las anomalías para los dos modelos combinados.

En la que se ha detectado que hay 24 anomalías que solo detecta KNN, 24 anomalías que solo detecta SVM y 6 anomalías que detectan ambos. De modo que si en una empresa se tuviera un sistema de alertas se remendaría priorizar estas anomalías críticas (puntos rojos de la gráfica).

5.5. Reseñas contradictorias

En este apartado vamos a implementar un filtro de coherencia semántica con el objetivo de detectar cuando una valoración textual (review) contradice a la valoración del cliente (recomendación).

Para llevar a cabo esta tarea hemos utilizado dos diccionarios genéricos para el dominio de palabras con las que trabajamos. Generando así dos diccionarios:

- Diccionario positivo: Cuenta con términos asociados a la satisfacción (eficiente, genial, excelente, recomendable, perfecto, bueno...).
- Diccionario negativo: Contiene términos asociados a la insatisfacción (problemático, lento, caro, regular, alto, elevado...).

Una vez tenemos los diccionarios a cada reseña se le asigna un valor calculado a partir de:

$$Puntuacion = \left(\sum \text{Palabras Positivas} \right) - \left(\sum \text{Palabras Negativas} \right)$$

Para determinar si una reseña es contradictorias hemos determinados dos reglas de contradicción:

- Falso negativo: El usuario usa un lenguaje positivo pero lo marca como no recomendado.
- Falso positivo: El usuario usa un lenguaje negativo pero lo marca como recomendado.




Ilustración 29: Visualización de reseñas contradictorias.

Finalmente, podemos observar que tan solo hay contradicciones en la parte de que habla mal en la reseña pero si lo recomienda.

Tras realizar la limpieza de reseñas contradictorias y unir los datos mediante un *inner join* (para quedarnos solo con vehículos que tienen reseñas verificadas), hemos re-entrenado el modelo Random Forest del apartado 4.2. Los resultados comparativos son los siguientes:

Métrica	Modelo 4.2	Modelo 4.5	Diferencia
Nº Datos	489	306	-37% de datos menos
R2	0.924	0.865	-6.4% pero ajuste
MAE	1.555€	1.990€	+435€ de error

Tabla 4: Comparación de modelos de los puntos 4.2 y 4.5.

A primera vista al ser el dataset sin datos contradictorios debería mejorar el modelo, pero no nos encontramos con eso. Esto se debe principalmente a la diferencia en el volumen de datos con el que hemos tenido que trabajar. Y como hemos aplicado el algoritmo de Random Forest para predecir el precio (es un algoritmo que funciona mejor con muchos datos), ha generalizado peor. Con este experimento queda demostrado que a veces que más valioso conservar el volumen de datos que filtrar.

5.6. Predicción de precio de venta

El objetivo de este apartado es comparar diferentes modelos de regresión para predecir el precio de venta real del vehículo y determinar cuál presenta mejor rendimiento predictivo.

Se han implementado los siguientes modelos:

1. Regresión Lineal Múltiple
2. Árbol de Decisión

3. SVM
4. Perceptrón Multicapa

a) Regresión Lineal Múltiple

Resultados Obtenidos:

- $R^2 = 0.9369$
- $RMSE = 1829$
- $MAE = 1501$
- R^2 ajustado = 0.9271

El modelo explica aproximadamente el 93% de la variabilidad del precio, lo que indica que la relación entre las variables explicativas y el precio es altamente estructurada y cercana a lineal. Además, el R^2 ajustado (0.9271) confirma que el modelo no está sobre ajustado.




Ilustración 30: Gráfica del valor real vs predicho de la regresión lineal múltiple.

Apreciamos una alineación muy marcada de los puntos alrededor de la diagonal, lo que indica una elevada capacidad explicativa del modelo. La dispersión es relativamente reducida y homogénea a lo largo del rango de precios.

La fuerte alineación sugiere que la relación entre las variables explicativas y el precio es predominantemente lineal, lo que justifica que la regresión lineal múltiple haya superado a modelos no lineales más complejos.




Ilustración 31: Gráfico de residuos de la regresión lineal múltiple.

No observamos un patrón en forma de abanico ni incremento progresivo de la varianza a medida que aumenta el precio predicho.

Esto sugiere que la varianza del error es relativamente constante, cumpliendo uno de los supuestos clásicos del modelo lineal.

El análisis visual confirma los resultados métricos obtenidos:

- Alta capacidad explicativa (R^2 elevado).
- Errores distribuidos de forma estable.
- Ausencia de sesgo estructural.
- No evidencia de sobreajuste.

El comportamiento gráfico respalda la selección de la Regresión Lineal Múltiple como modelo final, ya que muestra estabilidad, coherencia y consistencia en todo el rango de precios.

b) Árbol de Decisión

Resultados Obtenidos:

- $R^2 = 0.883409$
- RMSE = 2487
- MAE = 1790
- R^2 ajustado = 0.865365

El modelo tiene buen rendimiento, pero inferior a la regresión lineal. El árbol puede perder precisión cuando la relación es más continua que segmentada.




Ilustración 32: Gráfico del valor real vs predicho con el árbol de decisión.

A diferencia de la regresión lineal, aquí observamos un patrón menos continuo. Los puntos tienden a agruparse en niveles horizontales, lo cual es característico de los árboles de decisión ya que:

- El árbol divide el espacio en segmentos.
- Cada hoja asigna un único valor promedio a todos los casos dentro de ese nodo.
- Por tanto, las predicciones no son completamente continuas, sino discretizadas.

El modelo explica bien la variabilidad, pero con menor precisión que la regresión lineal.




Ilustración 33: Gráfico de residuos del árbol de decisión.

Los residuos muestran:

- Mayor dispersión que en la regresión lineal.
- Algunos errores extremos superiores a ± 8000 €.
- Mayor variabilidad en rangos altos.

Esto indica que el árbol comete errores más grandes en ciertos segmentos. Apreciamos una ligera mayor dispersión conforme aumenta el precio predicho, lo que sugiere cierta heterocedasticidad. También observamos columnas verticales de puntos, reflejando nuevamente la naturaleza segmentada del modelo.

El modelo de *Árbol de Decisión* muestra una adecuada capacidad de segmentación del mercado, reflejada en la tendencia positiva entre valores reales y predichos. No obstante, el carácter discreto de sus predicciones genera agrupaciones horizontales y una mayor dispersión respecto a la recta de identidad. El análisis de residuos revela errores más amplios y mayor variabilidad en rangos altos de precio, lo que explica su menor rendimiento comparativo frente a la regresión lineal múltiple.

a) SVM

Resultados Obtenidos:

- $R^2 = 0.750724$
- RMSE = 3636
- MAE = 2515
- R^2 ajustado = 0.712146

El R^2 es alto, pero no mejor que el modelo básico de regresión múltiple antes creado.




Ilustración 34: Gráfico de valor real vs predicho para el modelo SVM.

El modelo SVM muestra una capacidad predictiva aceptable ($R^2 \approx 0.75$), aunque claramente inferior a la regresión lineal.

En el gráfico se observa una dispersión moderada respecto a la recta ideal, especialmente en los valores altos del precio. Esto indica que el modelo tiende a suavizar las predicciones y presenta cierta dificultad para capturar correctamente los extremos del mercado. Este comportamiento es característico de modelos con regularización elevada o con parámetros que priorizan estabilidad frente a ajuste fino. El SVM captura tendencias generales del precio, pero pierde precisión en rangos altos, donde la variabilidad es mayor.




Ilustración 35: Gráfico de residuos del modelo SVM.

El análisis de residuos confirma que el SVM no presenta sesgo sistemático grave, pero sí una mayor dispersión del error en comparación con la regresión lineal.

Esto refuerza la idea de que, aunque el modelo no lineal es capaz de capturar cierta complejidad, el fenómeno estudiado presenta una estructura mayoritariamente lineal.

a) Perceptrón Multicapa

Resultados Obtenidos:

- $R^2 = 0.847297$
- RMSE = 2846
- MAE = 2156
- R^2 ajustado = 0.823665

Aunque es un modelo más complejo, no supera a la regresión lineal. Esto sugiere que el problema no requiere una estructura altamente no lineal.




Ilustración 36: Gráfico del valor real vs predicho del modelo perceptrón multicapa.

A diferencia de los demás modelos, en este podemos observar:

- Dispersión moderada principalmente en los valores más altos.
- No se aprecia un colapso hacia un valor promedio, lo que indica que el modelo aprende.

El gráfico muestra una alta concentración de observaciones en torno a la recta, lo que indica un ajuste adecuado del modelo. La dispersión observada es moderada y no evidencia sesgos sistemáticos pronunciados.

El análisis de los residuos revela una distribución aproximadamente centrada en cero, sin patrones estructurales claros. La ausencia de tendencias o formas definidas en el gráfico de residuos sugiere que el modelo no presenta problemas significativos de especificación, ni evidencia clara de heterocedasticidad.




Ilustración 37: Gráficos de residuos del modelo perceptrón multicapa.

El R^2 indica que el modelo explica aproximadamente el 84.7% de la variabilidad observada en el precio, lo que representa un alto poder explicativo dentro del contexto del problema.

La diferencia reducida entre R^2 y R^2 ajustado sugiere que el modelo no presenta un sobreajuste y que las variables incluidas contribuyen de manera efectiva a la capacidad predictiva.

• **Conclusión Final**

Tras la comparación de los distintos modelos de predicción del precio de venta (Regresión Lineal Múltiple, Árbol de Decisión, SVM y Perceptrón Multicapa), concluimos que la Regresión Lineal Múltiple es el modelo más adecuado para este problema.

En primer lugar, presenta el mayor coeficiente de determinación ($R^2 \approx 0.94$), lo que indica que explica aproximadamente el 93% de la variabilidad del precio del vehículo. Además, el R^2 ajustado es muy próximo al R^2 , lo que confirma que el modelo no está sobreajustado y que las variables incluidas aportan información relevante real.

Desde el punto de vista del error, también obtiene los valores más bajos de RMSE y MAE, lo que demuestra mayor precisión en la predicción respecto al resto de modelos.

En segundo lugar, los modelos más complejos (SVM y Perceptrón Multicapa) no lograron superar su rendimiento, a pesar de incorporar estructuras no lineales y mayor capacidad de modelado.

También, frente al Árbol de Decisión, la regresión lineal muestra mayor estabilidad y menor dispersión del error, especialmente en rangos altos de precio.

La elección de la Regresión Lineal Múltiple se justifica por:

- Mayor capacidad explicativa.
- Menor error de predicción
- Mayor estabilidad.
- Interpretabilidad de los coeficientes.
- Adecuación a la naturaleza lineal del problema.

En conclusión, aunque modelos más complejos pueden capturar relaciones no lineales, en este caso no aportan mejoras significativas. Por tanto, la Regresión Lineal Múltiple se selecciona como modelo final por ofrecer el mejor equilibrio entre precisión, simplicidad e interpretabilidad.

6. Fase 5: Interpretación y Evaluación

6.1. Algoritmos para la clasificación del segmento de mercado

El objetivo de esta fase es entrenar algoritmos de *Machine Learning* capaces de clasificar automáticamente el segmento de un vehículo (Compacto, SUV, Sedán, Executive, Deportivo) basándose exclusivamente en sus características técnicas.

Para maximizar la eficiencia de los modelos y evitar el sobreajuste (*overfitting*), aplicamos inicialmente un algoritmo *Random Forest* con el propósito de medir la importancia matemática de cada variable. Previamente, se excluyeron variables de "estado" (kilometraje, averías, antigüedad), ya que estas determinan el desgaste del coche, pero no su segmento de fábrica.




Ilustración 38: Gráfico de la importancia de variables para definir el segmento.

El *Random Forest* identificó que la segmentación del mercado automovilístico está fuertemente dominada por sus prestaciones (potencia) y su posicionamiento económico (precio), dejando otras variables en un plano secundario. De modo que tras, realizar diferentes pruebas obteniendo diferentes resultados hemos decidido quedarnos con las 4 características más relevantes ya que son con las que mejores resultados hemos obtenido en los diferentes modelos.

Tras aislar las características ganadoras y estandarizar los datos, entrenamos cuatro modelos de clasificación supervisada. Utilizamos la técnica *GridSearchCV* con validación cruzada (5 particiones) para encontrar de forma automatizada la mejor configuración para cada uno:

- **Naive Bayes:** Se optimizó con un suavizado (*var_smoothing*) de $1e-09$.

- **K-Nearest Neighbors (K-NN):** Alcanzó su mejor versión analizando a los 3 vecinos más cercanos y ponderando sus votos por *distance* (dando más peso a los vehículos más idénticos).
- **Árbol de Decisión:** Su mejor configuración utilizó el criterio de entropy (ganancia de información) y limitó su crecimiento a una profundidad máxima de 10 niveles, permitiendo capturar reglas de negocio detalladas.
- **Support Vector Machine (SVM):** El ajuste óptimo requirió un kernel no lineal (rbf), con una alta penalización al error ($C = 1000$) y un parámetro gamma de 10, lo que le permite trazar fronteras de decisión muy complejas y adaptadas a los datos.

Al evaluar los modelos optimizados con el conjunto de prueba, se obtuvieron las siguientes métricas:

Modelo	Exactitud (Accuracy)	Precisión	Sensibilidad (Recall)	F1-Score	ROC-AUC
Naive Bayes	0.308	0.324	0.308	0.279	0.599
K-NN	0.841	0.844	0.841	0.839	0.917
Árbol de Decisión	0.750	0.761	0.750	0.745	0.881
SVM	0.858	0.875	0.858	0.858	0.941

Tabla 5: Evaluación de los modelos para la segmentación del mercado.




Ilustración 39: Gráfica comparativa de los modelos de clasificación de segmento de mercado.

De la comparativa de resultados, extraemos las siguientes conclusiones clave para el negocio:

1. **El Modelo Ganador (SVM):** Las Máquinas de Vectores de Soporte (SVM) demostraron ser el algoritmo más eficaz. Con un *F1-Score* de 0.858 y un *Accuracy* de casi el 86%, el modelo es altamente fiable para clasificar el segmento de un coche nuevo que entre en la base de datos.
2. **Excelente Capacidad de Separación:** El SVM logró un impresionante ROC-AUC de 0.941 (muy cercano al 1.0 perfecto). Esto significa que, en

el espacio multidimensional, los clústeres de "SUVs", "Compactos" o "Deportivos" están muy bien definidos y el modelo rara vez confunde clases diametralmente opuestas.

3. **El Caso de Naive Bayes:** El pobre rendimiento de Naive Bayes (Accuracy del ~30%) era previsible. Este algoritmo asume que las variables son independientes entre sí. Sin embargo, en la automoción, el precio, la potencia y el consumo están fuertemente correlacionados (un coche más potente siempre suele ser más caro y consumir más). Al violarse esta regla de independencia, el modelo colapsa.
4. **K-NN como Alternativa:** El modelo basado en vecindad (K-NN) logró unos resultados fantásticos y muy cercanos al ganador (F1-Score: 0.839, ROC-AUC: 0.917). Esto refuerza la idea de que vehículos con especificaciones técnicas similares pertenecen casi inevitablemente al mismo segmento comercial.

6.2. Sistema de recomendación

En este punto hemos desarrollado un motor de recomendación avanzado que combina el comportamiento de usuarios y las características del producto por segmento.

Para trazar los perfiles hemos usado especificaciones técnicas y opiniones de los clientes, codificando la recomendación lo que permite que el sistema penalice matemáticamente aquellos vehículos que, pese a tener buenas especificaciones sobre el papel, presentan un bajo índice de recomendación histórica por parte de la comunidad.

Al carecer de datos demográficos explícitos de los usuarios (como edad o sexo), aplicamos una técnica de perfilado implícito. El "perfil" de un cliente se construye calculando el promedio exacto de todas las características (técnicas y valorativas) de los vehículos con los que ha interactuado.

Para la creación del sistema hemos empleado dos algoritmos de K-NN, utilizando la métrica de similitud del coseno.

- **Recomendación basada en perfiles similares:** Este primer algoritmo K-NN escanea clientes con gustos y presupuestos matemáticamente equivalentes. El recomendador sugiere los vehículos más populares (Top Ventas) entre ese grupo de usuarios afines. Esto garantiza recomendaciones respaldadas por la validación social ("Otros usuarios con tu exacto perfil técnico y nivel de exigencia acabaron comprando esto").
- **Características técnicas preferidas por segmento:** Primero identifica el segmento favorito del usuario objetivo (ej. "SUV"). A continuación, calcula el arquetipo ideal de ese segmento de mercado promediando los requerimientos de motor, precio y las puntuaciones cualitativas más exigidas por todos los compradores históricos de ese segmento (revelando, por ejemplo, si los compradores de SUVs priorizan el "Confort" frente al

"Diseño"). Así el segundo algoritmo K-NN escanea el catálogo único de la marca y localiza los vehículos reales cuyas especificaciones tengan la mayor similitud del coseno respecto a ese arquetipo ideal. Esto asegura que se recomienden alternativas matemáticamente optimizadas para el segmento preferido del cliente.

Así si comprobamos el funcionamiento de estos dos algoritmos obtenemos lo siguiente:

- Para el cliente con id *CUST131* obtenemos:

```
REQUISITO 1: Clientes con tus mismos gustos (diseño, confort...) compraron:  
-> Toyota RAV4 (6 coincidencias)  
-> Renault Clio (6 coincidencias)  
  
REQUISITO 2: Recomendación basada en preferencias del segmento 'Compacto'  
(Este segmento valora principalmente: 1º Seguridad y 2º Eficiencia)  
(Presupuesto medio: 36515€ | Potencia: 172CV)  
  
Te recomendamos estos modelos que encajan con ese perfil:  
-> Peugeot 408 (Alta afinidad técnico-cualitativa)  
-> Volkswagen Golf (Alta afinidad técnico-cualitativa)  
-> Volkswagen Tiguan (Alta afinidad técnico-cualitativa)
```

Donde se puede observar que coche te recomiendo para clientes con tus mismo gustos y que coches te recomiendo para tu tipo de coches preferido según el segmento que más quieras.

- Para el cliente con id *CUST199* obtenemos:

```
REQUISITO 1: Clientes con tus mismos gustos (diseño, confort...) compraron:  
-> Peugeot 308 (4 coincidencias)  
-> Volkswagen Tiguan (3 coincidencias)  
  
REQUISITO 2: Recomendación basada en preferencias del segmento 'Deportivo'  
(Este segmento valora principalmente: 1º Confort y 2º Seguridad)  
(Presupuesto medio: 33941€ | Potencia: 170CV)  
  
Te recomendamos estos modelos que encajan con ese perfil:  
-> BMW Serie 1 (Alta afinidad técnico-cualitativa)  
-> Volkswagen Tiguan (Alta afinidad técnico-cualitativa)  
-> Toyota RAV4 (Alta afinidad técnico-cualitativa)
```

Donde se puede observar que coche te recomiendo para clientes con tus mismo gustos y que coches te recomiendo para tu tipo de coches preferido según el segmento que más quieras.

7. Conclusión y resolución de objetivos

En conclusión, este proyecto ha transformado datos brutos en un ecosistema de Machine Learning con valor estratégico. Hemos probado que el mercado automovilístico se rige principalmente por factores técnicos (potencia y precio), logrando predecir el valor residual y el precio del vehículo. Además, desarrollamos posibles herramientas antifraude eficaces mediante la detección de anomalías (SVM y K-NN) y automatizamos la clasificación de segmentos. Finalmente, la creación de un recomendador híbrido, permitiendo ofrecer un asesoramiento personalizado que cruza la ingeniería del vehículo con el comportamiento de usuarios afines, optimizando así la estrategia de ventas y conversión.

Para finalizar, al inicio de este proyecto, se plantearon una serie de preguntas de negocio orientadas a desentrañar el funcionamiento del mercado de la automoción a través de los datos. Tras completar todas las fases del ciclo de vida del dato, damos respuesta a cada uno de los objetivos planteados:

1. ¿Qué características determinan el precio de un vehículo?

Mediante los modelos de regresión y el análisis de importancia de variables (Importancia de características con Random Forest), se determinó que el mercado tasa los vehículos basándose casi exclusivamente en características técnicas y de posicionamiento (potencia en CV y precio base). Las variables de percepción del cliente y comerciales aportan matices, pero el núcleo del precio lo dicta la ingeniería del coche.

2. ¿Podemos segmentar vehículos por perfil de uso y eficiencia?

Sí, utilizando algoritmos de clasificación supervisada (destacando las Máquinas de Vectores de Soporte), hemos logrado categorizar con alta precisión (F1-Score superior al 85%) a los vehículos en sus respectivos segmentos. El modelo aprendió a segmentarlos basándose únicamente en su huella técnica (potencia, eficiencia global, cilindrada, precio base y coste mantenimiento), demostrando que el uso y la eficiencia definen matemáticamente la categoría del coche.

3. ¿Qué factores predicen los costes de mantenimiento?

A lo largo del modelado y la exploración de datos, se observó que los costes de mantenimiento no son aleatorios. Las características técnicas que más influyen son:

- Potencia
- Antigüedad
- Precio
- Tipo de combustible (los coches eléctricos serán mas caros que los diésel e híbridos)

4. ¿Existen patrones en las ventas por temporada y región?

Durante las fases de preparación y exploración, se incorporaron las variables de fecha de venta y región del vendedor. Aunque estas variables permiten contextualizar el volumen de negocio macroeconómico, a nivel algorítmico se demostró que el precio individual de un vehículo depende mucho más de su estado intrínseco (desgaste y motor) que del momento temporal o código postal de la transacción

5. ¿Cómo predecir el valor residual de un vehículo?

Se han construido con cierto éxito modelos predictivos supervisados (como Árboles de Decisión). Alimentando estos algoritmos con el espectro completo de datos (características técnicas, desgaste por kilometraje, mantenimiento y opiniones), el sistema es capaz de estimar el precio del valor residual con un R^2 superior al 0.81, cometiendo un error medio (MAE) muy acotado frente al valor real de mercado.

6. ¿Influye la percepción del cliente en el precio del vehículo?

La influencia es secundaria, las pruebas realizadas eliminando las reseñas contradictorias mediante Procesamiento de Lenguaje Natural (NLP) evidenció que limpiar el "ruido subjetivo" de las opiniones no mejoraba la predicción del precio. De hecho, reducir la cantidad de datos para buscar opiniones perfectas penalizó al modelo. El mercado automovilístico es inelástico frente a la subjetividad: el valor lo retiene el vehículo, no la opinión.

7. ¿Es posible detectar vehículos con precios anormales a partir de sus características?

Si, la implementación comparativa de algoritmos K-NN y SVM en su variante de regresión demostró ser una herramienta antifraude muy fiable. El sistema es capaz de aislar "vehículos tóxicos", marcando cruces rojas en vehículos cuyo precio de venta exigido es injustificadamente alto en comparación con la tendencia general del mercado o con sus "vecinos" mecánicamente idénticos.