



Curso especialización en inteligencia artificial y big data

Trabajo Febrero 2026:Sistema Análisis del mercado de Automoción

Profesor: Sebastián Rubio Valero

Noviembre 2025



La actividad consiste en aplicar la metodología KDD en la venta de vehículos de segunda mano. Debes realizar un documento pdf con todas las fases de esta metodología, presentado diagramas, análisis, conclusiones, etc. Debes entregar lo siguiente:

- Un cuaderno Jupyter Notebook comentado, explicando las partes más importantes
- Un documento pdf

DATOS

Los datos que se proporcionan son sintéticos, no se ajustan a la realidad. Una vez localizados los datos, realizar una primera inspección,

0.1 Vehículos.json

En este fichero tiene la relación de marcas de coche, diferentes modelos, con los siguientes campos

- vehiculo-id: Identificador único
- marca: Marcas de coches
- modelo: modelos de cada marca
- anio-fabricacion: Año en el que se fabricó el coche
- combustible: Gasolina/Diésel/Eléctrico
- transmision: automática/Manual
- potencia-cv: potencia del coche en caballos
- cilindrada: cilindros que tiene el coche
- consumo-urbano: consumo urbano
- consumo-extraurbano: consumo en carretera
- emisiones-co2: emisiones
- precio-base: precio de salida
- segmento: Compacto/Sedán/Executive/SUV/Deportivo

0.2 ventas-mantenimiento.csv

En este fichero tienes datos sobre el coste de mantenimiento de las diferentes marcas y modelo. Las características son las siguientes:

- venta-id: Identificador de venta
- vehiculo-id: Un identificador del vehiculo
- fecha-venta: fecha de venta
- región-vendedor: son las diferentes regiones de españa no estan todas
- precio-venta-real: precio real de venta
- kilometraje-venta: kilómetros que tenía el coche cuando se vendió
- servicios-realizados: Número de veces que ha pasado por el taller
- coste-mantenimineto-anual: coste de mantenimiento
- incidencias-mecánicas: número de averías
- valor-residual-estimado: precio recalculado

0.3 Opiniones-clientes.xml

Otros datos necesarios son las opiniones de los clientes sobre las marcas y modelos

- review-id: identificación de reseña
- vehiculo-id:identificador de vehículo
- cliente-id: identificador de cliente
- puntuacion: puntos a todos los aspectos del coche
- confort: puntuación del confort del coche
- seguridad: puntuación a la seguridad del coche
- eficiencia: puntuación a la eficiencia del coche
- diseño: puntuación al diseño del coche
- fiabilidad: puntuación a la fiabilidad del coche
- recomendacion: si/no
- text-reseña: texto de la reseña

1 FASE 1: Selección y compresión del dominio

1.1 Análisis Exploratorio del Dominio

El objetivo es comprender el contexto automotriz y las variables disponibles.

1. Analizar distribución de marcas, modelos y segmentos
2. Identificar relaciones entre características técnicas y precios
3. Estudiar patrones de ventas y mantenimiento
4. Documentar hipótesis sobre factores que afectan valor residual

1.2 Definición de Objetivos de Minería

En este punto se da una relación que preguntas que te debes hacer. La respuesta a estas preguntas la encontrarás cuando hayas realizando las fases posteriores. Al final del documento deberás responder a estas preguntas

- ¿Qué características determinan el precio de un vehículo?
- ¿Podemos segmentar vehículos por perfil de uso y eficiencia?
- ¿Qué factores predicen los costes de mantenimiento?
- ¿Existen patrones en las ventas por temporada y región?
- ¿Cómo predecir el valor residual de un vehículo?
- Cualquier otra cuestión que se plantee por el alumno

2 FASE 2: Preprocesamiento y limpieza

En esta fase tienes que trabajar con los datos, aplicando técnicas vistas en clase

2.1 Integración de Múltiples Fuentes

En este punto debes unir los diferentes dataset de forma que consideres que será útil para el modelo/s de A.A. La operaciones que se suelen realizar, si lo consideras necesario, son las siguientes:

1. Realizar joins por vehiculo-id

2. Verificar rangos realistas (años, precios, consumos)
3. Identificar vehículos sin datos completos
4. Crear dataset unificado para minería

2.2 Limpieza y Tratamiento de Valores Anómalos

Deberás detectar los valores outliers y realizar el tratamiento adecuado. Debes documentar que valores son outliers, como los has tratado, etc. Las acciones a realizar son las siguientes:

1. Identificar precios fuera de rangos realistas
2. Detectar consumos imposibles (0 o extremadamente altos)
3. Tratar valores missing en puntuaciones
4. Normalizar variables técnicas (potencia, cilindrada)

2.3 Ingeniería de Características

En esta sección se crean o eliminan características . La decisión de eliminar unas características debe estar precedida en un análisis de datos, empleando algunos modelos de A.A (de los vistos en clase). Las acciones a realizar, se procede, son:
Variables a crear:

1. eficiencia-global: $\frac{\text{consumo-urbano} + \text{consumo-extraurbano}}{2}$
2. ratio-precio-potencia: $\frac{\text{precio-base}}{\text{potencia-cv}}$
3. antigüedad: $\text{anio} - \text{actual} - \text{anio} - \text{fabricacion}$
4. categoria-emisiones: Eco/Media/Contaminante basado en CO2
5. indice-fiabilidad: basado en incidencias y opiniones
6. depreciacion-anual: $(\text{precio} - \text{base} - \text{valor} - \text{residual}) / \text{antigüedad}$

Variable a eliminar: Aquellas que consideres que no son necesarias para hacer Data Mining. De momento sólo sabemos hacerlo estudiando la correlación.

3 FASE 3: Transformación

Esta no debes hacerla por que aún no se ha estudiado en clase. Nos hace falta estudiar algunos modelos no supervisados, que veremos en la siguiente evaluación. De todas formas, lo dejo enunciado para que lo tengas en cuenta en los próximos proyectos.

3.1 Reducción de Dimensionalidad

1. PCA para variables técnicas correlacionadas (consumos, potencia, emisiones)
2. Selección de características para predicción de precios
3. Agrupación de marcas por segmento de mercado
4. Creación de índices compuestos (ej: índice-calidad-total)

3.2 Discretización y Binnig

Transformación de variables continuas

1. Segmentar potencia en categorías (Baja/Media/Alta/Deportiva)
2. Discretizar consumo en niveles de eficiencia
3. Categorizar precios en segmentos de mercado
4. Agrupar emisiones según normativas europeas

4 FASE 4: Minería de Datos (KDD)

Responde a las siguientes cuestiones

1. ¿Qué características determinan el precio de un vehículo?
2. ¿Podemos segmentar vehículos por perfil de uso y eficiencia?
3. ¿Qué factores predicen los costes de mantenimiento?
4. ¿Existen patrones en las ventas por temporada y región?
5. ¿Cómo predecir el valor residual de un vehículo?

4.1 Árboles de Decisión para predecir valor residual

Generar un odelo predictivo de depreciación OBJETIVO: Predecir categoría de valor residual (Alto/Medio/Bajo)

VARIABLES PREDICTORAS

1. marca, combustible, transmisión
2. potencia-cv, eficiencia-global
3. antigüedad, kilometraje
4. coste-mantenimiento, incidencias-mecanicas
5. puntuacionconjunta, recomendacion

4.2 Regresión Múltiple para Precios, utiliza random forest

Responde a las siguientes preguntas justificando ¿Que características de las reseñas predicen mejor el precio del vehículo?¿Es vinculante las reseñas?.

4.3 Análisis de Sentimiento en Reviews usando Naive Bayes

¿Cómo influye el sentimiento en los precios de los coches?¿Qué características de los vehículos predicen mejor las reseñas positivas?

4.4 Utiliza el algoritmo K-nn y SVM para detectar anomalías en los precios

¿De que forma puedes utilizar un modelo K-nn para detectar las anomalías en los precios?. Genera un modelo visualizando los resultados

4.5 Reseñas contradictorias

Encuentra reseñas que son contradictorias, y realiza un nuevo conjunto de datos eliminando aquellos clientes y vehiculos. Realiza un análisis predicción de ventas con este nuevo conjunto de datos

4.6 Predicción del precio de venta

Genera modelos de predicción Regresión múltiple o polinomial, árboles de decisión, svm , perceptron multicapa. Compara los diferentes modelos con las siguientes métricas

- MSE
- RMSE
- MAE
- R cuadrado
- R cuadrado ajustado

5 Fase 5: Interpretación y Evaluación

5.1 Aplica Algoritmos para la clasificación de Segmento de Mercado

El objetivo es clasificar vehículos en segmentos usando Naive Bayes, K-nn, Árboles de Decisión Clasificación, SVM Indica en que configuración de hiperparámetros y que características dan mejores resultados en la clasificación . Realiza un comparación de cada modelo dando las siguientes métricas en aquellos casos en los el set de datos lo permita:

1. Exactitud (Accuracy)
2. Precisión
3. Sensibilidad
4. F1-Score
5. ROC-AUC score

5.2 Ejercicios prácticos

Generar un modelo para la recomendación teniendo en cuenta las siguientes características

1. Vehículos que han comprado clientes con perfiles similares

2. Características técnicas preferidas por segmentos de clientes
3. Precios y características de la competencia